

L'intelligence artificielle qui vous appartient.

JARVIS OS — infrastructure d'IA distribuée, 100 % locale, **zéro cloud**, **RGPD natif**. Vos données ne quittent jamais votre parc. Preuves mesurées, pas de promesses.

0 € cloud récurrent

 **RGPD natif** · on-premise

< 0 token facturé

modèles **open-source** locaux

17/07/2026

LE CONSTAT

L'IA cloud vous coûte cher — et vous expose.

Abonnements qui gonflent, données envoyées chez des tiers, latence et coût à chaque requête, verrouillage fournisseur. Pour une entreprise, c'est un risque financier **et** réglementaire.

✗ Solutions cloud classiques

- ✓ ✗ Données hébergées hors de l'entreprise
- ✓ ✗ Abonnements récurrents qui augmentent
- ✓ ✗ Verrouillage fournisseur (vendor lock-in)
- ✓ ✗ Coût & latence à chaque requête

✓ JARVIS OS

- ✓ Données 100 % chez le client — RGPD natif
- ✓ Infrastructure possédée — 0 € cloud récurrent
- ✓ Compatible **toutes** les IA, modèles open-source
- ✓ S'adapte au parc existant — smartphone → cluster

PREUVES CHIFFRÉES

Des résultats mesurés le 17/07/2026 — pas des estimations.

99,6 %

succès sur 4 413 appels LLM

91,8 %

du trafic reste local (M1)

~1,1s

réponse interactive médiane

51 tok/s

débit max

10,51 %

WER vocal (dataset FLEURS)

0 €

token payant - 100 % local

RETOUR SUR INVESTISSEMENT

Ce que ça change, concrètement.

Résultats annoncés côté client (déploiement AlkymIA-OS) et livrable de référence chronométré.

Impact opérationnel client

Déploiement type — traitement des commandes

-14 h/sem

temps libéré

×6

plus rapide

+340 %

ROI à 12 mois

0 €

cloud


Livrable standard : JARVIS vs freelance

Scraper « catalogue → CSV » (livrable Fiverr/Upwork type)

Freelance



JARVIS OS



200× plus rapide, qualité 1000/1000 lignes, 100 % on-premise

Coût annuel — interprète vocal (1 poste)

Transcription 100 % locale (Whisper CUDA, 20× temps réel) vs API cloud



DIFFÉRENCIATEURS

Cloud classique vs JARVIS OS

DIMENSION	CLOUD CLASSIQUE	JARVIS OS
Localisation des données	dans le cloud	100 % chez le client
Modèle de coût	abonnements croissants	infrastructure possédée · 0 € récurrent
Dépendance fournisseur	verrouillage	toutes IA, modèles open-source
Matériel	imposé	s'adapte au parc existant
Pilotage	souris / écran	voix (STT + TTS intégrés)
Résilience	redémarrage manuel	auto-réparation < 8 s · uptime 99,7 %
Coût par requête	latence + facturation	cache hit 96,9 % · 0 token facturé

Un socle robuste, une feuille de route maîtrisée.

Cluster multi-nœuds sur matériel grand public. Le socle permanent (M1 + M2 + M5) assure la production ; la montée en capacité est planifiée et chiffrée.

État du parc


Socle permanent opérationnel · capacité d'extension identifiée

- ✓ **M1** — orchestrateur + LLM primaire (3 GPU, 28 Go VRAM inférence)
- ✓ **M5** — relay vocal + MCP + PostgreSQL (pipeline voix complet)
- ✓ ⚠ **M2** — nœud calcul (3× RTX4000, 24 Go) à réactiver

961 agents indexés · jusqu'à 1 435 composants · ~10 000 blocs 0-token · 169 skills-agents

Roadmap upgrade M1 — coût maîtrisé

3 scénarios chiffrés (prix marché relevés)



■ Meilleur ratio €/perf : AM4 + 128 Go DDR4 sur base existante

Souveraineté par conception.

RGPD natif

Aucune donnée ne quitte l'infrastructure. Bases & secrets on-premise (SQLite/PostgreSQL/Redis), sauvegardes chiffrées, secrets exclus de tout artefact.

Zero-Cloud

Communications inter-nœuds sur 127.0.0.1. Bascule cloud optionnelle, jamais imposée.

Open-source · MIT

Modèles open-source hébergés localement, pas de vendor lock-in. Code sous licence MIT, réutilisable.

Traçabilité

Chiffres figés sur décompte vérifié, chaque total traçable en une commande. Architecture entièrement documentée.

Passez à une IA que vous possédez.

Démonstration sur votre parc · audit d'infrastructure · déploiement sur mesure.

[Demander une démo →](#)