

JARVIS OS — Audit de cohérence

AUDIT DE COHÉRENCE DES CHIFFRES — Dossier de présentation JARVIS OS

Audit **lecture seule** des 6 sections `demo/pack/sections/*.md` (00 → 05). Aucun fichier de section n'a été modifié. Date : 2026-07-17. Légende verdict : ✓ cohérent · ⦿ à préciser (correct mais ambigu / manque de qualificatif) · contradiction (valeurs incompatibles entre sections).

1. Tableau des chiffres clés × sections

1.1 Agents

Chiffre	00 couverture	01 archi	05 écosystème	Signification	Verdict
129 Claude Code natifs	oui (« 129 agents Claude Code natifs »)	oui (§3.2 registre <code>~/ .claude/agents/</code> = 129)	oui (« 129 agents Claude Code natifs, façade la plus visible »)	registre Claude Code local M1	voir §2.1 — contredit par le 58 de la section 05
58 Claude natifs	—	apparaît indirectement (renvoi section 5)	oui (décompte 2 : <code>.claude/agents/*.md</code> = 58)	agents <code>.md</code> natifs	58 vs 129 pour la même notion « Claude natifs »
961 index cowork	oui	(implicite via renvoi §5)	oui (décompte 1, somme $848+82+28+3 = 961$ ✓)	index <code>jarvis-cowork/agent-index.json</code>	✓ arithmétique exacte, libellé constant
1 354 entreprise	oui	oui (annexe renvoi)	oui (décompte 2, somme = 1 354 ✓)	toutes couches consolidées	✓ somme exacte (961+58+71+169+95)
1 435 OMEGA	oui	oui	oui (décompte 3, somme = 1 435 ✓)	inventaire OMEGA (Legions incl.)	✓ somme exacte
928 slogan	oui (« 928 du slogan, à manier avec précaution »)	oui (§3.2 « 928 agents actifs, uptime 99,7 % »)	—	slogan <code>jarvis-linux</code>	⦿ voir §2.2 — présenté comme fiable en 01, comme douteux en 00
900+ écosystème	—	oui (§3.2 badge/README)	—	badge OpenClaw	⦿ 4 ^e chiffre « agents » non listé dans la note de rigueur du 00
6 Omega Master Agents	—	—	oui (décompte 3, cat. 10, <code>~/ .claude/agents/</code>)	agents <code>~/ .claude/agents/</code>	même chemin que le « 129 » et le « 58 » → 3 valeurs pour <code>~/ .claude/agents/</code>

1.2 GPU

Chiffre	00	01	02	03	Signification	Verdict
10 GPU (cluster)	oui (« 10 GPU »)	oui (« Total : 10 GPU », §2)	—	—	total cluster	la somme du tableau nœuds §2 donne 12 (4+3+2+1+2), pas 10
5 GPU (M1)	—	4 GPU listés M1 (2060 + 2×1660S + 3080)	« 4 GPU physiques sur M1 » mais 5 lignes dans le tableau	5 GPU M1 (2060 + 3×1660S + 3080)	GPU physiques M1	3 valeurs : 4 (tableau 01), « 4 » texte 02 + 5 lignes, 5 (03)
5 nœuds	oui	oui	—	(M1 seul)	topologie cluster	✓ constant

1.3 VRAM

Chiffre	00	01	03	Signification	Verdict
---------	----	----	----	---------------	---------

88 Go cumulée	oui	oui (§2 « somme lignes = 88 G » ✓ : 34+24+10+8+12)	—	VRAM cluster totale	⊙ la somme n'est juste que si M1=34 G (4 GPU) ; or M1 réel = 5 GPU = 40 G → vrai total = 94 G
34 G M1	—	oui (ligne M1 §2)	—	VRAM M1	incompatible avec §03 : 5 GPU M1 = 12+6+6+6+10 = 40 G
28 Go inférence	oui (« 28 Go dédiés inférence »)	—	oui (§7 « 28 672 MiB (28 GiB) », = 3×6144+10240 ✓)	VRAM inférence hors GPU0	✓ cohérent — et implique 3× 1660S , donc 5 GPU M1 (confirme le conflit ci-dessus)
68 G slogan	oui (note : « 928 mélange agents ») ; PAS le 68	oui (§2 « 68G description à corriger, retenir 88 G »)	—	valeur historique description	⊙ correctement signalé comme obsolète en 01, absent du 00

1.4 Skills

Chiffre	00	01	05	Signification	Verdict
169 skills-agents	oui (« 169 skills-agents »)	—	oui (décompte 2 : <code>~/.claude/skills/SKILL.md</code> = 169)	skills-agents indexés	✓ constant entre 00 et 05
53 skills	—	oui (§3.3 <code>~/.claude/skills/</code> = 53 ; annexe « retenu 53 »)	—	registre local M1	⊙ 53 vs 169 pour « <code>~/.claude/skills</code> » — dénombrements différents (dossiers vs SKILL.md) non explicité au lecteur du 00
52 / 61 / 86 / 127	—	oui (§3.3 : 52 orchestrator, 61 core, 86 cowork, 127 agents orchestrator)	—	par périmètre dépôt	⊙ foisonnement de valeurs skills — OK en interne §01, mais 00 n'affiche que 169
85 Skills Gemini CLI	—	—	oui (décompte 3, cat. 3)	<code>~/.gemini/skills/</code>	✓ périmètre distinct clair

1.5 Performance / benchmarks

Chiffre	Sections	Valeur	Verdict
Appels LLM	00, 02 (×2)	4 413	✓ constant
Taux succès	00, 02	99,6 % (4 397 ok / 16 err)	✓ constant (4397+16=4413 ✓)
Trafic local M1	00, 02	91,8 % (65,6+26,2 ✓)	✓ exact
Local total	02	98,6 % (91,8+6,8 ✓)	✓ exact
Fallbacks	02	894 (20,3 %)	✓ (894/4413 = 20,3 % ✓)
Latence interactive médiane	00, 02	~1,1 s / 1 114 ms	✓ cohérent
Débit max	00, 02	51 tok/s (cloud gratuit)	✓ constant
Latence « ~0,4 s » M1 hub	02 (§2 ×2)	~0,4 s	⊙ vs « ~1,1 s » interactif §2 tableau (1 114 ms) — deux « meilleures latences » différentes dans la même section 02
WER	00, 02	10,51 %	✓ constant
RTF vitesse	00 (« 20× »), 02 (« 20,2× »)	20× / 20,2×	⊙ arrondi mineur (20× vs 20,2×)
Coût cloud évité	00, 02	1 440–2 500 \$/an	✓ constant
BLEU	02	17,2	✓ (unique)
~1 % petaFLOP	00, 02	✓ constant	✓

1.6 Hardware / système (00, 02, 03)

Chiffre	Sections	Valeur	Verdict
RAM totale	03	46 GiB	✓
			⊙ collision visuelle avec « 28 Go

RAM utilisée charge	03	28 GiB	VRAM inférence » (deux 28 sans rapport)
Bande passante RAM	00, 02, 03	107 954 MiB/s (~108 GB/s)	✓ constant
ZRAM ratio	00, 02, 03	3,07:1	✓ constant
ZRAM détail	02 vs 03	02 : « 6,36 G → 1,98 G » · 03 : « 34 MiB → 9,3 MiB »	deux jeux de chiffres bruts pour le même ratio 3,07:1 (instantanés différents non datés distinctement)
ZRAM taille	03	24 GiB (00 dit « 24 Go »)	✓
CPU multi	00, 02, 03	14 560 ev/s	✓ constant
CPU single	02, 03	1 802 ev/s	✓
Scaling SMT	02 (8,08×), 03 (8.08×)	8,08×	✓
Fréq. courante	03	4026 MHz	✓ (unique)
HugePages statiques	03	512 pages = 1 GiB	⊙ §3 dit « 496 livres / 128 réservées » (512≠496+128=624) — incohérence interne §03
AnonHugePages	03	10,8 GiB	✓ (interne cohérent §4/§6)
Disque randread/write	02, 03	8 730 / 19 200 IOPS	✓ constant
Uptime	01 (§5)	99,7 %	⊙ aussi accolé au « 928 » douteux en §3.2
Auto-réparation	00, 01	< 8 s	✓ constant
Failover LB	01	< 3 s	✓
Cache hit	01	96,9 % (319 tok / 233 échanges)	✓ (unique)

1.7 GPU thermique live (02 vs 03) — instantanés

GPU	02 (§4)	03 (§7 live)	Verdict
RTX 2060 temp	54 °C, fan (n/a)	54 °C, fan 46 %	✓
1660S #2 (actif/défaillant)	73 °C , 100 % charge	74 °C , fan 0 % défaillant	⊙ 73 vs 74 °C (instantanés proches) ; rôles décrits différemment (02 : « actif 100 % » ; 03 : « ventilateur défaillant »)
GPU2 ventilateur défaillant temp	—	§7 dit « 0% / 74 °C » mais §ci-dessus (protection) dit « 88-89°C »	74 °C vs 88-89 °C pour le même GPU2 défaillant dans la même section 03
RTX 3080	70 °C	72 °C	⊙ 70 vs 72 °C
Widget « 5 GPU »	—	— (04 : « charge des 5 GPU », KPI « 44-66 °C »)	✓ le widget §04 dit 5 GPU → cohérent avec §03 (5 GPU M1), contredit §01/§02

1.8 Divers infra

Chiffre	Section	Valeur	Verdict
Containers Docker	01 (§3.5 « 24 MCP »), 05 (« 26 containers »)	26 containers actifs	✓ (24 = serveurs MCP, distinct)
Scripts Python	01 (480 core), 05 (2 533 jarvis-linux + 618 cowork)	—	⊙ périmètres différents non reliés (480 vs 2 533) — pas contradictoire mais peut dérouter
Blocs bibliothèque	00 (~10 000), 01 (~2 579 → ~9 661)	~10 000	✓ (10 000 = arrondi de 9 661)
n8n flows	01	65 flows (§3.5) / 24 h (§widget)	✓
Ports	01	18800-18803, 103 ports / 23 services	✓
Widget port	04	8899	✓ (unique)
KPI widget	04	39 file / 181 faites / 38 analysées / 200 fiches / 44 timers	⊙ exemple live, non relié aux autres sections (OK si étiqueté « exemple »)

2. Analyse des contradictions majeures

2.1 CRITIQUE — « Agents Claude natifs » : 129 vs 58 vs 6

Trois valeurs coexistent pour des notions présentées comme identiques ou se recouvrant, toutes pointant nominale^{ment} vers `~/claude/agents/` : - **129** : « agents Claude Code natifs » (00, 01 §3.2, 05 conclusion) — présenté comme *la façade la plus visible*. - **58** : `~/claude/agents/*.md` (05 décompte 2). - **6** : « Omega Master Agents » `~/claude/agents/` (05 décompte 3, cat. 10).

Le lecteur voit « 129 agents Claude natifs » en couverture, puis la section 5 additionne **58** (pas 129) dans le total 1 354, puis compte **6** dans le total 1 435. Le 129 n'est jamais décomposé ni réconcilié avec le 58. C'est l'incohérence la plus dommageable car elle touche le chiffre le plus mis en avant (couverture + conclusion).

2.2 CRITIQUE — GPU cluster : « 10 GPU » vs somme réelle 12/13

- Couverture et 01 §2 affirment « **10 GPU** ».
- Le tableau des nœuds (01 §2) additionne **12 GPU** (M1 4 + M2 3 + M5 2 + HP-A 1 + HP-B 2).
- Si l'on retient le M1 réel à **5 GPU** (§03), le cluster monte à **13 GPU**. Le « 10 » ne correspond à aucune addition du dossier. Aucune note de transparence n'existe (contrairement au 68/88 G VRAM qui, lui, est signalé).

2.3 CRITIQUE — M1 : 4 GPU vs 5 GPU (et 34 G vs 40 G VRAM)

- 01 §2 : M1 = **4 GPU** (RTX 2060 + **2×** GTX 1660S + RTX 3080), **34 G**.
- 02 §4 : texte « **4 GPU physiques** sur M1 » mais **5 lignes** dans le tableau (3× 1660S).
- 03 §7 et \$temp live : M1 = **5 GPU** (RTX 2060 + **3×** GTX 1660S + RTX 3080).
- 04 (widget) : « charge des **5 GPU** ».
- Le chiffre **28 Go inférence** (00 + 03) n'est atteignable qu'avec **3× 1660S** (3×6+10 = 28), donc **prouve** que M1 a bien 5 GPU. Conséquence : le tableau nœuds 01 (4 GPU / 34 G) est faux, et le total cumulé exact est **94 G**, pas 88 G. La majorité du dossier (02 tableau, 03, 04, et le calcul 28 Go) converge sur **5 GPU / 40 G M1** ; seuls le tableau nœuds 01 et une phrase du 02 disent 4.

2.4 Section 03 — GPU2 défaillant : 74 °C vs 88-89 °C

Dans la **même** section 03 : le tableau de règles de protection (§7) indique le ventilateur défaillant « à **88-89°C** sous charge », tandis que le tableau live juste en dessous montre GPU2 à **74°C**. Deux instantanés non distingués → paraît contradictoire.

2.5 ZRAM — deux jeux de chiffres bruts

Même ratio **3,07:1** mais : 02/00 → « 6,36 G → 1,98 G » ; 03 → « 34 MiB → 9,3 MiB ». Les deux donnent bien ~3,07 mais ce sont des instantanés très différents (Go vs MiB) sans horodatage distinct visible → un relecteur attentif y verra une erreur.

2.6 ● « 928 » du slogan présenté de deux façons

- 00 : explicitement « à manier avec précaution, mélange agents et parallélisme ».
- 01 §3.2 : « **928 agents actifs** (uptime 99,7 %) » sans réserve, comme un fait. Message incohérent selon la section lue.

2.7 ● Skills 53 vs 169 vs 52/61/86/127

La couverture n'affiche que **169 skills-agents** ; l'architecture retient **53** (annexe « retenu 53 local »). Ces deux chiffres ne sont jamais mis face à face pour le lecteur (169 = SKILL.md indexés cowork ; 53 = dossiers `~/claude/skills`). Sans note, un lecteur peut croire à une contradiction.

2.8 ● HugePages — arithmétique interne 03

§3 : « 512 pages » mais « 496 libres / 128 réservées » → 496+128 = 624 ≠ 512. Incohérence interne à corriger.

2.9 ● Latence « meilleure » : ~0,4 s vs ~1,1 s

Section 02 met en avant deux « meilleures latences prod » : le tableau §2 donne 1 114 ms (interactif court) tandis que le comparatif §2 donne « ~0,4 s » pour M1 via hub. Le 00 ne retient que ~1,1 s. À harmoniser (préciser que 0,4 s = prompt court « 60 mots », 1,1 s = interactif type).

3. Corrections recommandées (classées par gravité)

Gravité 1 — contradictions factuelles à corriger avant diffusion

1. **GPU cluster** : remplacer partout « 10 GPU » par le total réel des nœuds (**12**, ou **13** si M1 compté à 5) — OU ajouter

une note de transparence comme pour la VRAM. Le dossier ne doit pas afficher un total qui ne correspond à aucune de ses propres additions.

2. **M1 = 5 GPU / 40 G** : corriger le tableau nœuds 01 §2 (M1 : RTX 2060 + **3×** GTX 1660S + RTX 3080, **40 G**) et la phrase « 4 GPU physiques » du 02 §4. Recalculer alors la VRAM cumulée (**94 G**, pas 88 G) et la note 68/88 en conséquence. Le chiffre 28 Go d'inférence (3× 1660S) impose 5 GPU.
3. **Agents Claude natifs 129 vs 58** : choisir une définition unique. Si « 129 » = agents Claude Code (registre complet) et « 58 » = fichiers `.md` natifs, l'expliciter dans le décompte 2 de la section 05 (ex. « 58 `.md` natifs, sur 129 agents Claude Code enregistrés ») pour que le 129 de la couverture soit traçable dans le total 1 354.
4. **GPU2 03 : 74 °C vs 88-89 °C** : dater/étiqueter les deux instantanés ou aligner (« 88-89 °C observé en pic sous charge ; 74 °C au relevé du 17/07 »).

● Gravité 2 — cohérence de présentation

5. « **928** » : appliquer partout la même mise en garde que la couverture ; retirer ou nuancer « 928 agents actifs » présenté comme fait en 01 §3.2.
6. **ZRAM chiffres bruts** : n'exposer qu'un seul instantané (ou dater les deux : « run A : 6,36 G→1,98 G ; run B : 34 MiB→9,3 MiB »).
7. **HugePages 512 vs 496+128** : corriger l'arithmétique (§3 section 03).
8. **Latence 0,4 s / 1,1 s** : préciser le contexte de chaque valeur dans le 00 et le 02 pour éviter l'impression de deux « meilleures latences » concurrentes.
9. « **900+** » : l'ajouter à la note de rigueur du 00 (qui ne cite que 961/1354/1435/928) pour couvrir *tous* les chiffres d'agents visibles.

● Gravité 3 — clarté / confort de lecture

10. **Skills 53 vs 169** : ajouter une ligne d'explication (169 SKILL.md indexés vs 53 dossiers locaux) là où les deux apparaissent.
11. **Les deux « 28 »** (VRAM inférence vs RAM utilisée) : préciser les unités/nature pour éviter la collision visuelle.
12. **Scripts Python 480 vs 2 533/618** : relier les périmètres (core vs jarvis-linux vs cowork) d'un mot.
13. **RTF 20× / 20,2×** et **temps 70/72 °C, 73/74 °C** : harmoniser les arrondis entre 00 et 02/03.

4. Ce qui est solide (aucune action)

Les métriques de **performance de routage** (4 413 appels, 99,6 %, 91,8 % local, 894 fallbacks, 0,26 tentative), **RAM 108 GB/s**, **ZRAM 3,07:1**, **CPU 14 560 ev/s**, **WER 10,51 %**, **51 tok/s**, **coût cloud 1 440-2 500 \$/an**, **5 nœuds**, **28 Go inférence**, **auto-réparation < 8 s**, **cache hit 96,9 %** sont **parfaitement cohérents** d'une section à l'autre et arithmétiquement exacts. La couverture inclut déjà une louable « note de rigueur » sur les agents — il faut l'étendre aux GPU/VRAM et régler le 129/58.