

Franck Delmas

AI Engineer · Architecte Systèmes Distribués · Multi-GPU

Orchestration multi-agents · Infrastructure IA on-premise · Freelance / Mission longue

- 928 Agents IA
- 6 GPUs / 46GB VRAM
- 44 Repos GitHub
- Mission 18 mois

CHIFFRES CLÉS

928+	AGENTS IA ACTIFS
6	GPUS NVIDIA
<300ms	LATENCE VOCALE
835	PIPELINES AUTO
144+	OUTILS MCP
€21k	ÉCONOMIE/AN CLOUD

STACK TECHNIQUE

LANGAGES

- Python
- TypeScript
- Bash
- JavaScript

IA / LLM / ORCHESTRATION

- LangChain
- MCP Protocol
- Claude SDK
- LM Studio
- Ollama
- vLLM
- DeepSeek-R1
- Multi-agent

INFRASTRUCTURE / CLOUD

- Docker Swarm
- Docker Compose
- Linux
- systemd
- CUDA
- NVIDIA
- FastAPI
- WebSocket

DATA / BASES DE DONNÉES

- PostgreSQL
- Redis
- SQLite3
- Elasticsearch
- SQLAlchemy

VOICE / REAL-TIME

- Whisper CUDA
- faster-whisper
- Silero VAD
- PyAudio
- ElevenLabs

FRONTEND / DASHBOARD

- React
- Node.js
- WebSocket

ADÉQUATION FLAIR GROUP

IA & Data Expert — JARVIS OS, TradeOracle
Innovation R&D Expert — multi-agent, MCP, LLM
Infrastructure Cloud Solide — Docker Swarm, GPU
Développement Agile Solide — 570+ QA scripts
Cybersécurité Partiel — secrets mgmt, on-premise

DISPONIBILITÉ

Disponible

Mission freelance 18 mois
ou CDI client final

550-700 €/j TJM

PROFIL

Ingénieur IA indépendant spécialisé dans la conception et l'opération de systèmes distribués multi-GPU. Auteur de **JARVIS OS v17.0** — un OS IA autonome orchestrant 928 agents sur 6 GPUs avec 835 pipelines self-healing. Expert en orchestration multi-LLM, pipelines temps réel et infrastructure on-premise à coût minimal. Approche R&D : itérations rapides, métriques mesurables, zéro dépendance cloud.

PORTFOLIO — PROJETS GITHUB

JARVIS OS v17.0

OS IA autonome — Projet flagship · Score Claude Code 98/100

🏠 jarvis-os-public

Système d'exploitation IA distribué en 9 couches cognitives, orchestrant 928+ agents spécialisés sur un cluster 6 GPUs / 46GB VRAM. Zero cloud dependency — traitement 100% on-premise. Interface voice-first avec pipeline CUDA <300ms. 835 chaînes d'automation self-healing, 144+ outils MCP exposés, 2 658 commandes vocales nativement reconnues.

928+ 46GB 835 2 658 91.4%

AGENTS ACTIFSVRAM GPUPIPELINES AUTOCOMMANDES VOCALESPYTHON CODEBASE

- L1

Hardware

6x NVIDIA GPU, CUDA, cluster 3 machines
- L2

OS

Ubuntu/Debian optimisé, systemd
- L3

Data

SQLite3 distribué synchronisé
- L4

Inférence

LM Studio · Ollama · vLLM · load balancing
- L5

Protocole

144+ MCP handlers
- L6

Agents

928 agents spécialisés
- L7

Orchestration

Claude Agent SDK · consensus voting
- L8

Pipeline

n8n · Python · self-healing chains
- L9

Interface

Voice CUDA · WebSocket dashboard

Python CUDA LM Studio Ollama vLLM MCP Claude SDK SQLite3 Docker WebSocket FastAPI n8n

JARVIS-CLUSTER — La Créatrice

Infra GPU distribuée · Docker Swarm · 3 nœuds physiques

🏠 JARVIS-CLUSTER

Infrastructure multi-nœuds orchestrant 3 machines physiques (M1 Master 6 GPUs, M2 Detector, M3 Orchestrator) via Docker Swarm. Pipeline de dispatch en 9 étapes avec failover adaptatif, circuit breaker, monitoring thermique GPU et endpoints OpenAI-compatibles. ROI : breakeven vs cloud en <3 mois.

3 9 €30/mois €21k/an

NŒUDS PHYSIQUESÉTAPES DISPATCHCÔÛT OPÉRATIONNELÉCONOMIE VS CLOUD

Docker Swarm Python FastAPI WebSocket systemd Linux GPU Thermal Circuit Breaker OpenAI API

TradeOracle

Trading crypto autonome · Multi-LLM consensus · MEXC Futures

🏠 TradeOracle

Agent de trading crypto autonome exécutant des futures sur 800+ paires MEXC via un système de consensus multi-modèles (Domino Pipeline). Score composite 70/100 requis avant exécution. Risk management 3-tier avec TP à +1.5%, +3%, +7% et SL à -1.2%. Dashboard temps réel FastAPI + WebSocket.

800+ 62% 40+ 3 LLM

PAIRES CRYPTOWIN RATE BREAKOUTOUTILS MCPCONSENSUS VOTING

Python LangChain FastAPI Gemini 3.0 LM Studio MCP SQLAlchemy MEXC API WebSocket

jarvis-whisper-flow

jarvis-whisper-flow

STT CUDA temps réel · Privacy-first · 99+ langues

Pipeline speech-to-text on-premise avec faster-whisper + CUDA. Latence <300ms sur RTX 3060, WER 3.2% (large-v3). Détection d'activité vocale Silero VAD, 26 commandes intégrées, hot-reload des skills sans restart. 100% local, aucune donnée envoyée à un tiers.

<300ms 3.2% 99+ 26

LATENCE RTX 3060WER LARGE-V3LANGUES SUPPORTÉESCOMMANDES VOCALES

faster-whisper CUDA Silero VAD PyAudio Docker NVIDIA toolkit PipeWire Python

TradeOracle-Nexus-Elastic

TradeOracle-Nexus-Elastic

Plateforme analytique financière · Elasticsearch · Monte Carlo

Plateforme d'analyse financière avec backtesting Monte Carlo, indexation Elasticsearch des signaux de marché et pipeline de données haute fréquence. Visualisation temps réel des performances de stratégies de trading.

Elasticsearch Python Monte Carlo Backtesting FastAPI SQLAlchemy

EXPÉRIENCE

AI Engineer Indépendant — Architecte Systèmes IA Distribués

Freelance · 2023 – présent · Remote / France

- Conception et déploiement de JARVIS OS : OS IA autonome orchestrant 928 agents sur cluster 6 GPUs
- Architecture multi-agent avec consensus LLM (Claude, Gemini, DeepSeek, modèles distillés)
- Infrastructure Docker Swarm multi-nœuds avec failover adaptatif et économie €21k/an vs cloud
- Développement de pipelines STT temps réel CUDA (latence <300ms, 3.2% WER)
- Système de trading crypto autonome multi-LLM sur 800+ paires MEXC Futures
- 44 repositories publics GitHub, 144+ outils MCP, 835 pipelines d'automation self-healing

Développeur Full Stack & Data Engineer

Missions antérieures · Python · FastAPI · React · PostgreSQL · Elasticsearch

- Développement d'APIs FastAPI avec WebSocket pour dashboards temps réel
- Pipelines ETL, indexation Elasticsearch, analytics Monte Carlo
- Automation navigateur (CDP Chrome DevTools Protocol)
- Déploiements Docker, monitoring GPU, scripting Linux/Bash

POURQUOI FLAIR GROUP — MISSION 18 MOIS

Ce que j'apporte

- Expertise IA rare sur le marché ESN
- Autonomie totale sur systèmes complexes
- Culture R&D + résultats mesurables
- Maîtrise complète du stack cloud/on-prem
- Engagement sur durée (projet JARVIS = 12+ mois)

Valeurs partagées (Flair)

- Transparence — code open-source, métriques publiques
- Engagement — 44 repos, contribution active
- Innovation — MCP Protocol, multi-agent (2024)
- Respect — documentation soignée, tests 570+